

On a un modèle génératif  $M$  complexe qui se décompose en trois morceaux  $M = (M_1, M_2, M_3)$  comme suit :

$$M_1 : Y|X^{I_1}, X^{I_2}, Z \sim X^{I_1} A_{I_1} + X^{I_2} A_{I_2} + \varepsilon \quad (1)$$

$$M_2 : X^{I_2}|X^{I_1}, Z \sim X^{I_1} B_{I_1}^{I_2} + \varepsilon_{X^{I_2}} \quad (2)$$

$$M_3 : X^{I_1}|Z \sim GM(\alpha) \quad (3)$$

On pose  $\theta = (\alpha, \Sigma, \Sigma_{X^{I_2}}, B_{I_1}^{I_2}, A_{I_1}, A_{I_2})$  Pour un  $Z$  donné on a donc

$$P_{M,Z}(Y, X^{I_1}, X^{I_2}|\theta) = P_{M,Z}(X^{I_1}|\theta)P_{M,Z}(X^{I_2}|X^{I_1};\theta)P_{M,Z}(Y|X^{I_2}, X^{I_1};\theta) \quad (4)$$

$$= P_{M_3,Z}(X^{I_1}|\alpha)P_{M_1,M_2,Z}(X^{I_2}|X^{I_1};\Sigma, \Sigma_{X^{I_2}}, B_{I_1}^{I_2}, A_{I_1}, A_{I_2})P_{M_1,M_2,Z}(Y|X^{I_2}, X^{I_1};\Sigma, \Sigma_{X^{I_2}}, B_{I_1}^{I_2}, A_{I_1}, A_{I_2}) \quad (5)$$

$P_{M_3,Z}(X^{I_1}|\alpha)$  vit tout seul et est estimé par Mixmod. On sait également que

$$P_{M_2,Z}(X^{I_2}|X^{I_1};\Sigma, \Sigma_{X^{I_2}}, B_{I_1}^{I_2}, A_{I_1}, A_{I_2}) = P_{M_2,Z}(X^{I_2}|X^{I_1};\Sigma_{X^{I_2}}, B_{I_1}^{I_2}) \text{ et} \quad (6)$$

$$P_{M_1,Z}(Y|X^{I_2}, X^{I_1};\Sigma, \Sigma_{X^{I_2}}, B_{I_1}^{I_2}, A_{I_1}, A_{I_2}) = P_{M_1,Z}(Y|X^{I_2}, X^{I_1};\Sigma, A_{I_1}, A_{I_2}) \quad (7)$$

De manière générale les gens s'arrêtent là, et obtiennent le modèle complet... qui ne tient pas compte de la structure. Mais nous, nous ne sommes pas juste sous  $M_2$  pour les sous-régression ni juste sous  $M_1$  pour  $Y$ . Donc la dépendance persiste (c'est ce qui permet que la contrainte aie une utilité, sinon elle serait inutile).

Du coup, il faut définir proprement  $P_{M_1,M_2,Z}(X^{I_2}|X^{I_1};\Sigma, \Sigma_{X^{I_2}}, B_{I_1}^{I_2}, A_{I_1}, A_{I_2})$  et  $P_{M_1,M_2,Z}(Y|X^{I_2}, X^{I_1};\Sigma, \Sigma_{X^{I_2}}, B_{I_1}^{I_2}, A_{I_1}, A_{I_2})$

On a  $Y|Z \sim X^{I_1} A_{I_1} + X^{I_2} A_{I_2} + \varepsilon$  mais le modèle  $M$  signifie aussi que :

$$Y|Z \sim X^{I_1} A_{I_1} + X^{I_1} B_{I_1}^{I_2} A_{I_2} + \varepsilon_{X^{I_2}} A_{I_2} + \varepsilon \quad (8)$$

on sait que quand on connaît  $X_{I_1}$ ,  $X_{I_2}$ , et  $B_{I_1}^{I_2}$ , on connaît aussi (par  $M_2$ )  $\varepsilon_{X^{I_2}}$  de manière exacte (pas son paramètre  $\Sigma_{X^{I_2}}$  mais bien la valeur de la variable elle-même).

On se demande si  $P_{M_1,Z}(Y|X^{I_2}, X^{I_1};\Sigma, A_{I_1}, A_{I_2})$  est différent de  $P_{M_1,M_2,Z}(Y|X^{I_2}, X^{I_1};\Sigma, \Sigma_{X^{I_2}}, B_{I_1}^{I_2}, A_{I_1}, A_{I_2})$ . donc si (sous l'hypothèse du modèle  $M_2$ )  $\Sigma_{X^{I_2}}$  et  $B_{I_1}^{I_2}$  sont indépendants de  $(Y|X^{I_2}, X^{I_1};\Sigma, A_{I_1}, A_{I_2})$ .

Pour moi, il y a dépendance mais je n'arrive pas à l'expliquer. C'est a priori pour cela qu'on a besoin de faire du séquentiel en s'appuyant sur le  $A$  explicatif. Je vais continuer avec les formules d'indépendance, ne sachant pas faire autrement.

$\Sigma_{X^{I_2}}$  matrice diagonale constituée des  $\sigma_{X,j}$  (pour la variable  $j$  à gauche).

$$P_{M_3,Z}(X^{I_1}|\alpha) \quad \text{maximisé de manière indépendante (du reste et de la contrainte) par mixmod} \quad (9)$$

$$P_{M_2,Z}(X^{I_2}|X^{I_1}; \Sigma_{X^{I_2}}, B_{I_1}^{I_2}) = \prod_j \frac{1}{\sigma_{X,j}\sqrt{2\pi}} e^{-\frac{(X^j - X^{I_1} B_{I_1}^j)^2}{2\sigma_{X,j}^2}} \quad (10)$$

$$P_{M_1,Z}(Y|X^{I_2}, X^{I_1}; \Sigma, A_{I_1}, A_{I_2}) = \frac{1}{\sigma_Y\sqrt{2\pi}} e^{-\frac{(Y - X^{I_1} A_{I_1} - X^{I_2} A_{I_2})^2}{2\sigma_Y^2}} \quad (11)$$

On a  $P_{M,Z}(Y, X|\theta) = \mathcal{L}_{M,Z}(\theta; Y, X)$ . On passe à la log-vraisemblance :

$$L_{M_2,Z}(\Sigma_{X^{I_2}}, B_{I_1}^{I_2}; X^{I_2}|X^{I_1}) = \sum_j -\ln(\sigma_{X,j}\sqrt{2\pi}) - \frac{(X^j - X^{I_1} B_{I_1}^j)^2}{2\sigma_{X,j}^2} \quad (12)$$

$$L_{M_1,Z}(\Sigma, A_{I_1}, A_{I_2}; Y|X^{I_2}, X^{I_1}) = -\ln(\sigma_Y\sqrt{2\pi}) - \frac{(Y - X^{I_1} A_{I_1} - X^{I_2} A_{I_2})^2}{2\sigma_Y^2} \quad (13)$$

On va donc maximiser cette somme sous la contrainte  $A_{I_1} + B_{I_1}^{I_2} A_{I_2} = \hat{A}_{I_1}$  où  $\hat{A}_{I_1}$  est l'estimateur des coefficients des variables de  $X^{I_1}$  dans le modèle explicatif. La contrainte s'écrit aussi  $B_{I_1} A - \hat{A}_{I_1} = 0$  avec  $B$  tel que  $X = XB + \varepsilon_X$  donc  $B_{I_1}^{I_1} = I_{p_1}$ .

Vague impression : On n'exprime pas la dépendance dans la vraisemblance mais on l'exprime quand-même dans la contrainte donc ça compense. Par contre, je ne sais pas si la compensation est totale ou pas. Mais a priori on n'est pas optimaux (déjà parce qu'on s'appuie sur  $\hat{A}_{I_1}$ ) mais je ne pense pas que l'on puisse faire mieux en l'absence de vraisemblance explicite (et il y a probablement des soucis d'identifiabilité qui font qu'on est forcés de passer par le séquentiel).